TECHNICAL UNIVERSITY OF LIBEREC
Faculty of Mechatronics, Informatics
and Interdisciplinary Studies

# TECHNOLOGIE PRO BIG DATA
# CVIČENÍ I.

*Lukáš Matějů*

*4.10.2023 | TPB*

# ORGANIZACE

- základní informace
  - přednášející i cvičící
    - Lukáš Matějů
    - lukas.mateju@tul.cz
  - rozsah předmětu 2+2
  - veškeré materiály zveřejňovány na elearningu FM
- přednášky
  - každý pátek od 08:50
  - budova A, místnost A-A0303
  - účast nepovinná, ale vítaná

# ORGANIZACE

- cvičení
  - každý pátek od 10:40
  - budova A, místnost A-A0304
  - samostatné práce volně doplňující přednášky
  - 10 povinných a 10 bonusových úloh
    - každá bonusová úloha je za 1 bonusový bod
    - na vypracování a odevzdání úloh je 1 týden
    - odevzdává se výhradně na cvičeních
    - za každý týden zpožděného odevzdání je -1 bod
    - finální počet úloh může být ovlivněn odpadnutím výuky
  - 2 povolené absence
    - každá další absence je za -3 body

# ORGANIZACE

- zápočet
  - odevzdané a správně vyřešené povinné úlohy ze cvičení
- zkouška
  - prezenční
  - písemná
    - max 20 bodů
    - 5 otázek po 4 bodech
  - body ze cvičení jsou přenášeny ke zkoušce
  - zaměřená na základní koncepty probírané v rámci předmětu

# ORGANIZACE

- hodnocení
  - dvě varianty
  - jen za bonusové body ze cvičení…
    - 10 bodů -> 1
    - 9 bodů -> 2
    - 8 bodů -> 3
    - povinná docházka na přednášky i cvičení (2 povolené absence)
  - v případě absolvování písemné zkoušky
    - maximum 30 bodů (20 + 10)
    - ≥ 26 bodů -> 1 ≥ 24 bodů -> 1-
    - ≥ 22 bodů -> 2 ≥ 20 bodů -> 2-
    - ≥ 16 bodů -> 3 < 16 bodů -> 4
  - v případě odpadnutí výuky budou potřebné body upraveny

# CO BUDEME POUŽÍVAT?

- větší množství technologií pro velká data
  - Apache Spark, Apache Flink, Apache Kafka, …
  - často komplexnější instalace
  - ➢ Docker
    - v učebnách nainstalovaný
    - použití oficiálních image
  - ➢ cloudová řešení
    - v případě použití zdarma
  - obsluha
    - Python



# KONTEJNERIZACE

- řeší nedostatky klasické plné virtualizace
- plná virtualizace
  - na serveru je nainstalována softwarová komponenta hypervisor
    - umožňuje vytváření virtuálních strojů
  - každý virtuální stroj se chová jako samostatný server s vlastním OS
  - ➢ velké režijní náklady
- kontejnerizace
  - virtualizace jádra OS
  - kontejnery běží v rámci jednoho OS a sdílejí paměť, knihovny a další zdroje
    - kontejnery mohou být izolovány od okolního prostředí
    - a následně nasazeny v různých prostředích
  - ➢ snižuje režijní náklady
    - zdroje jsou také využívány efektivněji

# KONTEJNERIZACE

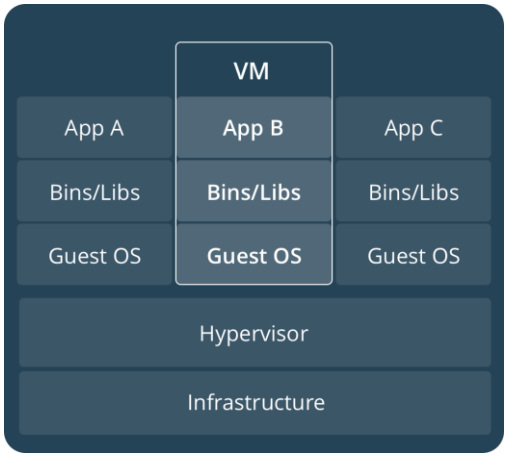


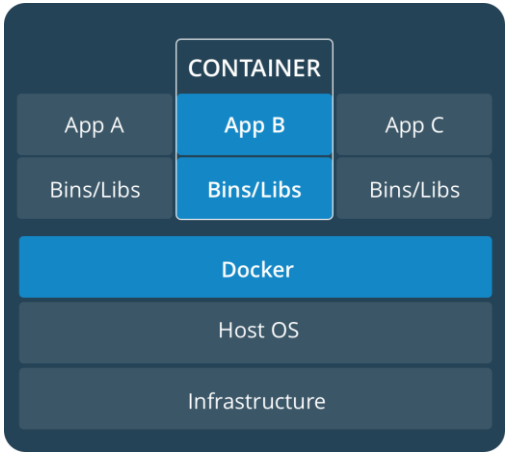

# DOCKER

- nejpopulárnější kontejnerová technologie
- izolace aplikací se všemi knihovnami, configy a dalšími soubory
  - kontejnery zajišťují spuštění aplikace v jakémkoliv prostředí
- umožňuje tedy vývoj, sestavení, spuštění i sdílení aplikace uzavřené v kontejneru
- web

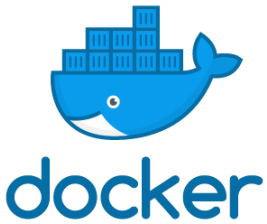

# DOCKER

- image
  - obsahuje vše potřebné pro běh programu
    - připravené prostředí bez lokálních úprav
  - zdrojové kódy, závislosti, soubory potřebné pro běh, …
- kontejner
  - běžící prostředí vytvořené z image
    - obsahuje data a lokální změny
  - přístup pouze ke svému souborovému systému, který spravuje Docker
    - výjimkou je použití Volumes pro ukládání dat – může být sdíleno mezi kontejnery

# DOCKER

- instalace (stažení)
  - verze pro Windows, MacOS, Linux
  - přímočará instalace
  - detailní návod na oficiálních stránkách
- ověření instalace
  - docker --version
  - docker run hello-world
- výpis všech kontejnerů (i zastavených)
  - docker ps -a
  - pouze běžící bez -a (--all)
- vytváření vlastní image
  - docker build –f /path/to/a/Dockerfile .

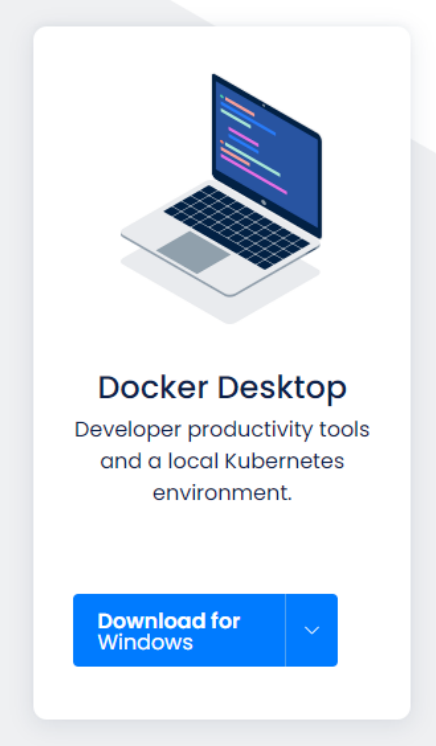

# DOCKER

- Docker Hub
  - služba pro hledání a sdílení image
  - obsahuje spoustu oficiálních image
    - Ubuntu, MongoDB, Python, …

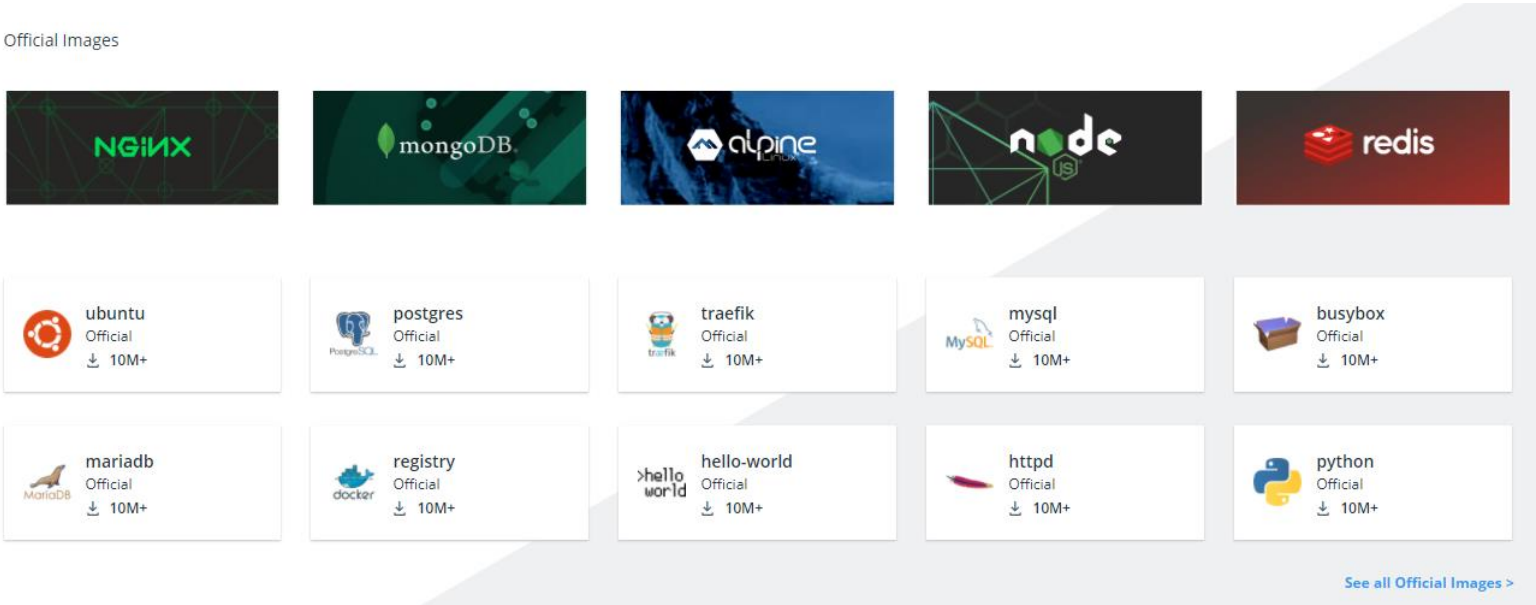

# ZÁKLADNÍ PŘÍKAZY

- spuštění kontejneru z MongoDB image
  - docker run -p 27017:27017 --name mongo_cv01 -d mongo:tag
    - -p (--publish) pro možnost komunikace na daném portu (port image:port host)
    - -d (--detach) pro běh kontejneru na pozadí
    - tag slouží pro uvedení verze
    - bez tagu se stáhne poslední verze (latest)
  - docker container exec –it mongo_cv01 bash
    - bash dovnitř mongo kontejneru
    - ukončení přes příkaz exit

# ZÁKLADNÍ PŘÍKAZY

- docker ps
  - výpis všech běžících kontejnerů
  - sloupec container id
- docker stop container_id
  - zastavení běžícího kontejneru
    - stačí uvést první 3 znaky container id
- docker ps
  - status exited u cvičného kontejneru
- docker start container_id
  - opětovné spuštění kontejneru

# ZÁKLADNÍ PŘÍKAZY

- docker stop container_id
  - opětovné zastavení
- docker container rm container_id
  - odstranění kontejneru včetně provedených změn
- docker image ls
  - výpis stažených image
- docker image rm image_id
  - smazání image
  - nelze smazat, pokud existuje kontejner (i zastavený), který image používá

# PYTHON

- web
- interpretovaný jazyk
- dynamická typová kontrola
- podpora různých programovacích paradigmat
  - objektové i funkcionální


- stažení a návod pro instalaci na různé OS
- možnost využít také např. Anacondu

# PYTHON

- pip
- package manager pro Python
- instalace balíčku (v příkazové řádce)
  - pip install pymongo
- odinstalace
  - pip uninstall pymongo
- zobrazení nainstalovaných balíčků včetně verze
  - pip list

# CVIČENÍ

- opakování – Python
- web scraper pro web iDNES.cz
  - navrhněte algoritmus, který bude postupně procházet články webového portálu iDNES.cz
  - ke každému článku uloží název článku, obsah článku, kategorii, počet fotografií, datum publikace a počet komentářů
    - pozor na neúplné údaje
  - informace bude ukládat do textového souboru ve formátu JSON
    - doplňte i funkcionalitu pro načtení dat
    - bude potřebná pro další cvičení
  - cílem je stáhnout alespoň 250 MB textových dat
  - BONUS: stáhněte minimálně 1 GB textových dat